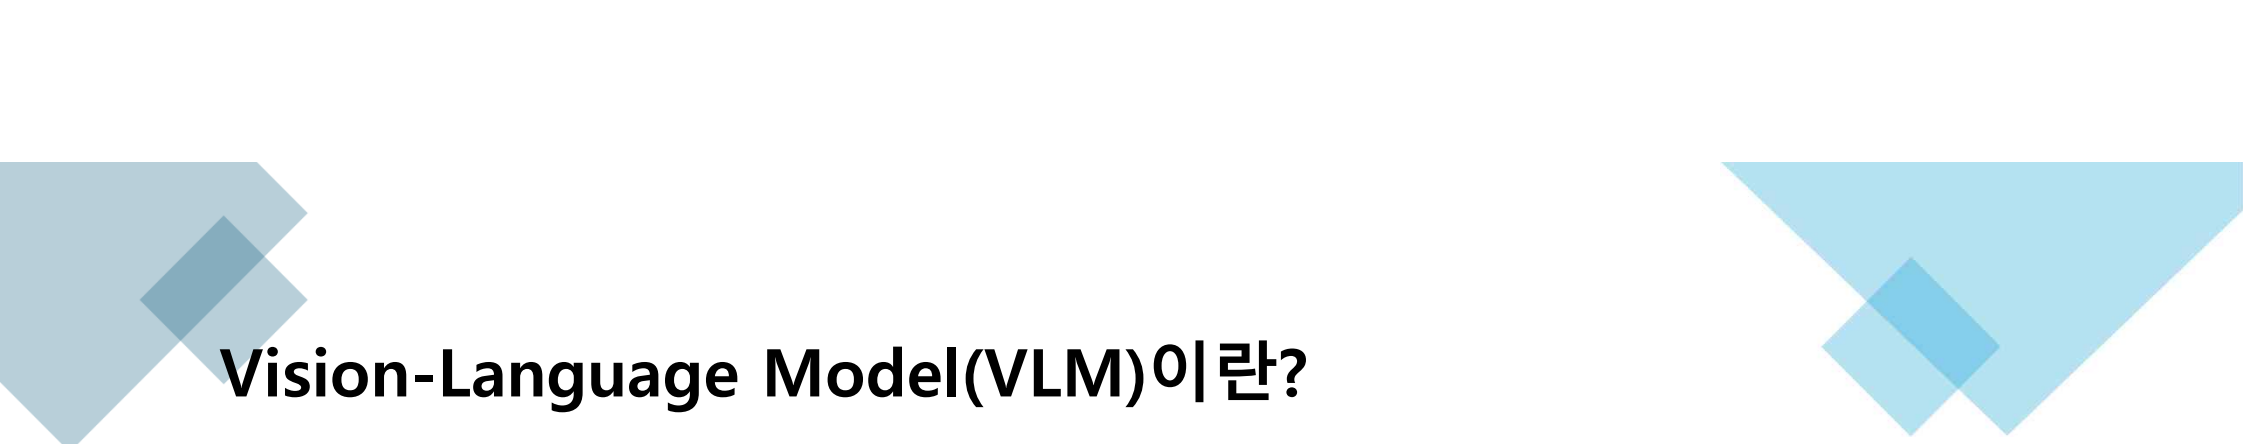


Vision Language Model

1. Vision Language Model (VLM)

소개



Vision-Language Model(VLM)이란?

Vision-Language Model(VLM)은 이미지와 텍스트를 동시에 이해하고 처리할 수 있는 멀티모달(Multimodal) 인공지능 모델이다.

기존의 컴퓨터 비전(Computer Vision) 모델은 이미지만 처리하고, 자연어 처리(NLP) 모델은 텍스트만 처리하였다. 반면 VLM은 이미지와 텍스트를 하나의 의미 공간(Embedding Space)에서 학습하여 시각 정보와 언어 정보를 함께 이해할 수 있다.



VLM의 등장 배경

기존 AI 모델의 한계

- CNN, ViT 등은 이미지 분류 및 객체 탐지에 강점
- BERT, GPT 등은 자연어 이해 및 생성에 강점
- 이미지와 텍스트를 함께 이해하기 어려움

예시

이미지:

- 강아지가 공원에서 뛰어노는 사진

질문:

- "강아지는 어디에 있는가?"

기존 Vision 모델

- 이미지 분석 가능
- 자연어 질문 이해 불가능

기존 NLP 모델

- 질문 이해 가능
- 이미지 내용 이해 불가능

VLM

- 이미지와 질문을 동시에 이해하여 답변 가능

VLM의 주요 특징

1. 멀티모달 이해(Multimodal Understanding)

이미지와 텍스트를 동시에 처리

예시

입력:

- 이미지
- "사진 속 사람은 무엇을 하고 있는가?"

출력:

- "자전거를 타고 있다."

2. 이미지-텍스트 정렬(Image-Text Alignment)

이미지와 텍스트를 동일한 의미 공간에 매핑

예시

이미지

- 고양이 사진

텍스트

- "Cat"

두 데이터가 가까운 임베딩 벡터를 가지도록 학습

3. 자연어 생성(Natural Language Generation)

이미지 내용을 자연어 문장으로 생성

예시


입력:

- 풍경 사진

출력:

- "푸른 하늘 아래 산과 호수가 보이는 풍경이다."

멀티모달 모델 파이프라인 다이어그램





구성 요소

Image Encoder

이미지를 특징 벡터로 변환

대표 모델


- CNN
 - Vision Transformer(ViT)
 - Swin Transformer
-

Text Encoder

텍스트를 임베딩 벡터로 변환

대표 모델

- BERT
 - RoBERTa
 - Transformer Encoder
-



Fusion Module

이미지 특징과 텍스트 특징을 결합

방법

- Concatenation
 - Cross Attention
 - Transformer Fusion
- 

대표적인 VLM 모델

CLIP

OpenAI가 개발

특징

- 이미지와 텍스트를 함께 학습
- Zero-Shot Image Classification 가능
- 대규모 이미지-텍스트 데이터셋 사용

활용

- 이미지 검색
- 이미지 분류
- 이미지 추천

BLIP

Salesforce Research 개발

특징

- Image Captioning
- Visual Question Answering(VQA)
- 멀티모달 이해

Qwen2.5-VL


Alibaba Cloud 개발

특징

- 최신 오픈소스 VLM 모델
- 이미지 이해와 자연어 생성 지원
- OCR 및 문서 분석 성능 우수
- 차트, 표(Table), PDF 이해 가능
- 로컬 실행 및 파인튜닝 가능

활용

- 문서 분석
- OCR
- Visual Question Answering
- AI Agent
- Visual RAG



LLaVA

특징


- Vision Encoder + LLM 구조
- ViT와 LLM을 연결하여 구성
- 이미지 기반 질의응답 지원
- 오픈소스 기반 VLM 연구에 널리 활용

Florence-2

Microsoft 개발

특징

- 다양한 Vision Task를 하나의 모델로 통합
- Object Detection
- OCR
- Image Captioning
- Segmentation 지원



GPT-4o

OpenAI 개발

특징

- 이미지, 텍스트, 음성을 통합 처리
 - 강력한 문서 이해 능력
 - 차트 분석 및 시각적 추론 가능
 - 멀티모달 Agent 구축 가능
- 



주요 활용 분야

Image Captioning

이미지를 설명하는 문장 생성

예시

입력:

- 강아지 사진

출력:

- "잔디밭에서 강아지가 뛰어놀고 있다."
-

Visual Question Answering (VQA)

이미지에 대한 질문 응답

예시

질문:

- "자동차는 몇 대 있는가?"

답변:

- "3대가 있다."
- 



Image Retrieval

텍스트로 이미지 검색

예시

검색어:

- "붉은색 스포츠카"

결과:


- 관련 이미지 반환
-

OCR + Document Understanding

문서 이미지 분석

예시

- 계약서 분석
- 영수증 분석
- 송장 분석



Visual RAG

이미지 기반 검색 증강 생성(RAG)

절차

1. 이미지 임베딩 생성
 2. 벡터 DB 저장
 3. 유사 이미지 검색
 4. LLM 응답 생성
- 

VLM과 기존 모델 비교

구분	Vision Model	LLM	VLM
이미지 이해	O	X	O
텍스트 이해	X	O	O
이미지 설명 생성	X	△	O
이미지 질의응답	X	X	O
OCR 활용	△	X	O
멀티모달 처리	X	X	O

대표 VLM 모델 비교

모델	개발사	오픈소스	OCR	문서 분석	VQA
CLIP	OpenAI	X	X	X	X
BLIP	Salesforce	O	△	△	O
LLaVA	오픈소스	O	△	△	O
Qwen2.5-VL	Alibaba	O	O	O	O
Florence-2	Microsoft	O	O	O	O
GPT-4o	OpenAI	X	O	O	O

대표 VLM 모델 계보

2021



CLIP

Contrastive Language-
Image Pre-training

- 이미지와 텍스트를 함께 학습한 최초의 대규모 모델
- 이미지-텍스트 임베딩 정렬
- Zero-Shot 이미지 분류 가능



2022



BLIP

Bootstrapping Language-
Image Pre-training

- 이미지 캡셔닝 성능 우수
- Visual Question Answering (VQA) 지원
- 생성형 멀티모달 모델의 발전



2023




LLaVA

Large Language and
Vision Assistant


- Vision Encoder + LLM 구조
- LLM과 연결하여 이미지 이해 및 대화 가능
- 오픈소스 기반으로 널리 활용





2. Vision Language Model (VLM) 구조

VLM 구조



1. 비전 인코더(Vision Encoder)

이미지를 숫자 벡터(Feature Vector)로 변환하는 역할이다.

입력

이미지

출력

시각 특징 벡터

대표 모델

- CLIP ViT
- SigLIP
- Vision Transformer(ViT)
- Swin Transformer

예시

강아지 사진



Vision Encoder



[0.21, -0.55, 0.33, ...]

비전 인코더는 이미지 속

- 색상
- 모양
- 객체
- 위치 정보

등을 추출한다.

2. 프로젝터(Projector)

비전 인코더가 생성한 특징 벡터를 LLM이 이해할 수 있는 형태로 변환하는 역할이다.

왜 필요한가?

비전 인코더와 LLM은 서로 다른 표현 공간(Embedding Space)을 사용한다.

즉,

비전 인코더 언어
≠
LLM 언어

상태이므로 중간 번역기가 필요하다.

이를 프로젝터(Projector)라고 한다.

프로젝터의 역할

시각 특징 벡터

|



Projector

|



이미지 토큰

쉽게 말하면


"이미지 특징 → LLM이 이해하는 토큰"

으로 변환한다.

대표 구현 방식

MLP 방식


LLaVA에서 사용



구조가 단순하고 빠르다.

Q-Former 방식

BLIP-2에서 사용



중요한 시각 정보만 추출한다.

3. 토크나이저(Tokenizer)

사용자의 질문을 토큰으로 분리한다.

예시

입력

이것은 무엇인가요?

출력

[이것은]
[무엇]
[인가요]
[?]

4. 텍스트 임베딩(Text Embedding)

토큰을 벡터로 변환한다.

[이것은]

|



[0.21, -0.44, 0.15, ...]

5. 이미지 토큰 + 텍스트 토큰 결합

프로젝터가 만든 이미지 토큰과 텍스트 토큰을 하나의 시퀀스로 합친다.

예시

```
[IMG1]  
[IMG2]  
[IMG3]  
[IMG4]  
[이것은]  
[무엇]  
[인가요]  
[?]
```

이를 멀티모달 입력 시퀀스(Multimodal Input Sequence)라고 한다.

6. LLM 디코더(LLM Decoder)

이미지 토큰과 텍스트 토큰을 함께 처리한다.

대표 모델

- LLaMA
- Qwen
- Gemma
- GPT 계열

입력

이미지 토큰
+
텍스트 토큰

출력

답변 토큰

예시

입력 이미지 : 갓을 쓴 캐릭터

질문 :
"이것은 무엇인가요?"

출력 :
"이 이미지는 갓을 쓴 캐릭터입니다."

구성요소 한눈에 보기

구성요소	역할
Vision Encoder	이미지 특징 추출
Projector	이미지 특징을 LLM 입력 형태로 변환
Tokenizer	문장을 토큰으로 분리
Text Embedding	텍스트를 벡터로 변환
Image Token	이미지를 표현하는 토큰
Text Token	텍스트를 표현하는 토큰
LLM Decoder	이미지와 텍스트를 함께 이해하여 답변 생성



감사합니다