

CLIP/BLIP 모델

1. CLIP

(Contrastive Language-Image Pretraining)

CLIP (Contrastive Language-Image Pretraining)

1. CLIP이란?

CLIP은 2021년 OpenAI가 발표한 Vision-Language Model(VLM)이다.

정식 명칭은 Contrastive Language-Image Pretraining이다.

기존 이미지 분류 모델은 "고양이", "강아지"와 같은 정해진 클래스만 분류할 수 있었다.

CLIP은 이미지와 텍스트를 함께 학습하여 이미지와 문장의 의미를 동일한 벡터 공간에 표현한다.

예를 들어 아래와 같은 이미지가 있다고 가정한다.

강아지가 잔디밭에서 뛰어노는 사진


CLIP은 다음과 같은 문장들과 비교할 수 있다.

A dog running
A cat sleeping
A car on the road

그리고 가장 의미적으로 가까운 문장을 찾아낸다.

contrastive : [언어] 대비 연구하는,
대조하는
contrastive linguistics : 대조 언어학

(1) Contrastive pre-training



(2) Create dataset classifier from label text




Figure 1. Summary of our approach. While standard image models jointly train an image feature extractor and a linear classifier to predict some label, CLIP jointly trains an image encoder and a text encoder to predict the correct pairings of a batch of (image, text) training examples. At test time the learned text encoder synthesizes a zero-shot linear classifier by embedding the names or descriptions of the target dataset's classes.

2. CLIP이 등장한 배경

기존 CNN 기반 이미지 분류 모델의 문제점

문제 1 : 고정 클래스

예를 들어 ImageNet으로 학습된 모델은

고양이
강아지
자동차
비행기

같은 정해진 클래스만 예측 가능하다.

새로운 클래스가 나오면 재학습이 필요하다.

문제 2 : 라벨링 비용

이미지 하나마다

dog
cat
car

같은 정답 라벨을 사람이 직접 붙여야 한다.

수억 장 수준에서는 매우 비싸다.

문제 3 : 일반화 부족

dog

만 학습한 모델은

golden retriever
husky

같은 새로운 표현에 약하다.

CLIP은 인터넷에 존재하는

이미지 + 캡션

데이터를 활용하여 문제를 해결하였다.

3. CLIP 핵심 아이디어

기존 모델

이미지
↓
CNN
↓
클래스 예측

CLIP


이미지
↓
Image Encoder
↓
Image Embedding

텍스트
↓
Text Encoder
↓
Text Embedding

두 임베딩 공간을 동일한 공간으로 학습한다.

4. CLIP 구조

CLIP 구조 (Contrastive Language-Image Pretraining)



5. Image Encoder

이미지를 벡터로 변환한다.

초기 CLIP에서는 두 종류를 사용하였다.

ResNet

이미지
↓
CNN
↓
Feature Vector

Vision Transformer (ViT)

이미지
↓
Patch 분할
↓
Transformer
↓
Feature Vector

최근에는 대부분 ViT 기반이 사용된다.

6. Text Encoder

텍스트를 벡터로 변환한다.

구조

문장
↓
Tokenizer
↓
Transformer
↓
Text Embedding

예시

A dog running in a park

↓

[320, 1452, 891, ...]

↓

768차원 벡터

7. 임베딩 공간(Embedding Space)

CLIP의 핵심이다.

학습 후에는 의미가 비슷한 것끼리 가까이 위치한다.

예시

강아지 사진



[0.12, 0.55, ...]

A dog



[0.13, 0.57, ...]

매우 가까움

A car



[-0.4, 0.8, ...]

멀리 위치



8. Contrastive Learning

CLIP의 가장 중요한 학습 방식이다.

"정답 쌍은 가깝게"

"오답 쌍은 멀게"

학습한다.

학습 데이터

예시

이미지

문장

강아지 사진

A dog

자동차 사진

A car

고양이 사진

A cat





배치(Batch)

Image1 ↔ Text1
Image2 ↔ Text2
Image3 ↔ Text3

Positive Pair

강아지 사진
A dog

가깝게 만든다.

Negative Pair

강아지 사진
A cat

강아지 사진
A car

멀어지게 만든다.



9. Cosine Similarity

CLIP은 벡터 간 각도를 이용한다.

수식

값 범위

값

1

0

-1

의미

매우 유사

무관

반대

예시

문장

Similarity

A dog

0.95

A cat

0.41

A car

0.03

따라서

A dog

선택

10. CLIP 학습 과정

Step 1

이미지 입력

강아지 사진



Image Encoder



Image Vector

Step 2

텍스트 입력

A dog



Text Encoder



Text Vector

Step 3

유사도 계산

Image ↔ Text

Step 4

Loss 계산

정답 쌍

Similarity ↑

오답 쌍

Similarity ↓

Step 5

반복 학습

수억 장 데이터를 통해 수행

11. Zero-Shot Classification

CLIP을 유명하게 만든 기능이다.

기존 CNN

학습

↓

고양이

강아지

자동차

만 분류 가능

CLIP

이미 학습된 모델에

A dog

A cat

A horse

A tiger

같은 문장만 제공하면 된다.

추가 학습 없이 분류 가능

예시

이미지

호랑이

후보

A dog

A cat

A tiger

A horse

유사도 계산

↓

A tiger

선택

12. CLIP 활용 분야

이미지 검색

"A red sports car"

검색



관련 이미지 반환

텍스트 기반 이미지 검색

Text-to-Image Retrieval

red helmet



헬멧 이미지 검색

이미지 기반 검색

Image-to-Image Retrieval

유사 제품 검색

Visual RAG

질문



이미지 검색



LLM



답변

산업 AI

품질 검사

scratch
crack
dent

설비 점검

rust
leak
damage

안전 점검

helmet
glove
vest

13. CLIP의 한계

객체 위치 파악 어려움

CLIP은

어디에 있는가?

보다

무엇인가?

를 잘한다.

객체 관계 이해 부족

사람이 의자 위에 앉아 있다

와

의자가 사람 위에 있다

차이를 완벽하게 이해하지 못한다.

문장 생성 불가

CLIP 출력은

임베딩 벡터

이다.


직접 캡션을 생성하지 못한다.

14. CLIP 이후 발전

CLIP의 성공 이후 수많은 VLM이 등장하였다.

CLIP은 현대 VLM의 출발점이라 불릴 만큼 영향력이 큰 모델이다.

Vision-Language Model 발전 흐름도



2. BLIP

(Bootstrapping Language- Image Pretraining)



BLIP (Bootstrapping Language-Image Pre-training)

1. BLIP이란?

BLIP은 2022년 Salesforce Research에서 발표한 Vision-Language Model(VLM)이다.

CLIP이 이미지와 텍스트를 연결(Alignment)하는 데 집중했다면, BLIP은 이미지를 이해하고 자연어를 생성하는 것까지 목표로 한다.

CLIP

→ 이미지와 텍스트 비교

BLIP

→ 이미지를 보고 설명 생성
→ 질문에 답변
→ 이미지와 텍스트 검색
까지 수행할 수 있다.

2. BLIP이 등장한 이유

CLIP의 한계

CLIP은 아래와 같은 작업은 잘 수행한다.

이미지

↓

A dog

A cat

A car

중 가장 유사한 문장 찾기

하지만 다음은 어렵다.

이 사진을 설명해줘

CLIP 출력


벡터 (Embedding)

BLIP 출력

A dog running in the park.

즉, 문장을 생성할 수 있다.

3. BLIP 전체 구조



4. Vision Encoder

이미지를 이해하는 부분이다.

주로

Vision Transformer 기반을 사용한다.

구조

```
이미지
↓
Patch 분할
↓
Patch Embedding
↓
Transformer
↓
Image Feature
```

예시

공장 컨베이어 벨트

↓

[0.12, -0.34, ...]

특징 벡터 생성

5. Multimodal Encoder

BLIP의 핵심이다.

이미지 특징과 텍스트 특징을 함께 이해한다.

CLIP

Image Encoder
Text Encoder

각각 독립적

BLIP

Image Feature
+
Text Feature
↓
Multimodal Encoder

동시에 처리

예시

이미지:
작업자가 설비를 점검

텍스트:
What is the worker doing?



Worker is inspecting equipment.

6. Text Decoder

BLIP이 CLIP과 가장 다른 부분이다.

Transformer Decoder를 사용한다.

입력

이미지 특징



출력

A worker is operating a machine.

문장을 한 단어씩 생성한다.

A
↓
worker
↓
is
↓
operating
↓
a
↓
machine




Figure 2. Pre-training model architecture and objectives of BLIP (same parameters have the same color). We propose multimodal mixture of encoder-decoder, a unified vision-language model which can operate in one of the three functionalities: (1) Unimodal encoder is trained with an image-text contrastive (ITC) loss to align the vision and language representations. (2) Image-grounded text encoder uses additional cross-attention layers to model vision-language interactions, and is trained with a image-text matching (ITM) loss to distinguish between positive and negative image-text pairs. (3) Image-grounded text decoder replaces the bi-directional self-attention layers with causal self-attention layers, and shares the same cross-attention layers and feed forward networks as the encoder. The decoder is trained with a language modeling (LM) loss to generate captions given images.

7. BLIP 학습 방법

BLIP은 세 가지 작업을 동시에 학습한다.

ITC

Image-Text Contrastive

CLIP과 유사

강아지 사진



A dog

가깝게 학습

ITM

Image-Text Matching

이미지와 문장이 맞는지 판단

예시

강아지 사진

A dog

정답

강아지 사진

A car

오답

출력

Match

Not Match

LM

Language Modeling

이미지 보고 문장 생성

예시

이미지



A dog is running in the park.

8. BLIP 동작 예시

예제 1 : 이미지 캡셔닝

입력

공장에서 작업자가 기계를 조작

출력

A worker is operating a machine.

예제 2 : Visual Question Answering

입력

질문:

What is the worker wearing?

출력

Safety helmet.

예제 3 : 이미지 검색

입력

red industrial valve



관련 이미지 검색



위까지는 모델링에 대한 학습 내용이고 다음 내용은 텍스트를 정제하기 위한 기법인 CapFlit(Captioning and Filtering)임.

1. Captioner: 웹에서 크롤링한 이미지에 대해 새로운 캡션을 생성. Image-grounded text decoder 형태이며, 웹에서 구한 이미지 I_w 로부터 합성 캡셔닝인 T_s 을 이미지당 하나씩 생성.

2. Filter: Image-grounded text encoder. ITC와 ITM 목적함수를 갖고, 이미지-텍스트가 매칭(positive)되는건지 구분하는 역할임.






Figure 3. Learning framework of BLIP. We introduce a captioner to produce synthetic captions for web images, and a filter to remove noisy image-text pairs. The captioner and filter are initialized from the same pre-trained model and finetuned individually on a small-scale human-annotated dataset. The bootstrapped dataset is used to pre-train a new model.

9. BLIP와 CLIP 비교

항목	CLIP	BLIP
발표	2021	2022
목적	정렬(Alignment)	이해 + 생성
출력	임베딩	자연어
캡셔닝	불가	가능
VQA	제한적	가능
검색	우수	가능
생성	불가	가능

10. BLIP의 대표 활용 사례

이미지 캡셔닝

사진



자동 설명 생성

VQA

Visual Question Answering

이미지

+

질문



답변

Visual RAG

이미지 검색



관련 정보 검색



LLM 답변

산업 현장

품질 검사

제품 표면 스크래치 발견

설비 점검

배관 누수 흔적 존재

안전 관리

작업자가 안전모를 착용하지 않음

11. BLIP의 가장 큰 특징

CLIP은

이미지 ↔ 텍스트

관계를 학습하는 모델이다.

BLIP은

이미지 이해
+
텍스트 생성
+
질문 응답
+
검색

을 하나의 모델에서 수행한다.

즉,

CLIP
= 이미지와 텍스트를 연결하는 모델

BLIP
= 이미지를 이해하고 설명하는 모델

이라고 이해하면 된다.

VLM 발전사 관점에서는

CLIP
↓
BLIP
↓
BLIP-2
↓
LLaVA

로 이어지며, BLIP은 "이미지-텍스트 정렬 중심 VLM"에서 "생성형 VLM"으로 발전하는 중요한 전환점이 된 모델이다.

3. BLIP-2

(Bootstrapping Language- Image Pretraining)



BLIP-2

Salesforce Research가 2023년에 발표한 VLM이다.


BLIP의 후속 모델이며, 이미지와 대규모 언어 모델(LLM)을 효율적으로 연결하는 것이 핵심 목표이다.

Paper: <https://arxiv.org/abs/2301.12597>

Git: <https://github.com/salesforce/LAVIS/tree/main/projects/blip2>


BLIP과 BLIP-2 차이

BLIP



이미지 이해와 텍스트 생성을 모두 직접 학습

BLIP-2



이미 학습된 Vision Encoder와 LLM을 그대로 활용

핵심 기술 : Q-Former

BLIP-2의 가장 중요한 구성 요소

Vision Encoder



Q-Former




LLM

Q-Former(Query Transformer)가 이미지 특징을 LLM이 이해할 수 있는 형태로 변환해 준다.

즉,



이미지 언어 번역기

역할을 수행한다.







<https://lunaleee.github.io/posts/blip-2/>

Input Image



Q-Former 구조

Vision Encoder의 이미지 특징을 LLM이 이해할 수 있는 형태로 변환하는 모듈



범례

- ❄️ 고정(Frozen) 파라미터
- 🟪 학습 가능한 파라미터
- 🟩 입력/특징 벡터

주요 기호

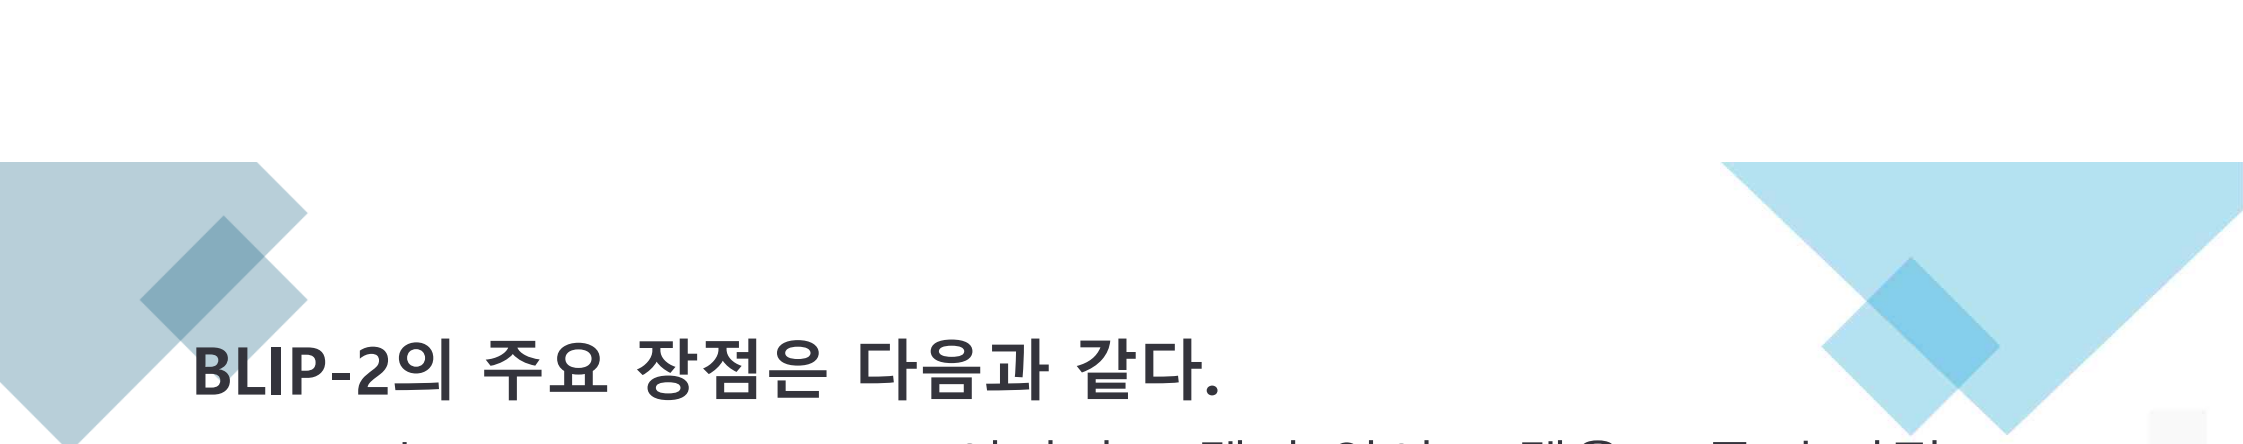
N : Image Features 토큰 수 (예: 197)
M : Query Tokens 수 (예: 32)
D : Hidden Dimension
L : Transformer Layer 수

핵심 아이디어

- Learnable Query Tokens가 이미지 특징을 '질의'하여 중요한 정보를 추출하고, 이를 LLM이 이해할 수 있는 형태로 변환한다.

특징

- ✓ ViT와 LLM은 그대로 사용 (학습 비용 절감)
- ✓ Q-Former만 학습
- ✓ 다양한 LLM에 연결 가능



BLIP-2의 주요 장점은 다음과 같다.

- BLIP-2는 frozen pre-trained 이미지 모델과 언어 모델을 모두 효과적으로 활용한다. Representation learning stage, generative learning stage의 두 단계로 pre-train된 Q-Former를 사용하여 modality gap을 해소했다.
 - FlanT5 LLM을 기반으로 하는 BLIP-2는 자연어 지침에 따라 zero-shot image-to-text generation이 가능하다. 이를 통해 다양한 시각적 추론 및 대화가 가능하다(아래 그림 예시).
 - Frozen unimodal 모델과 경량 Q-Former를 사용하므로 BLIP-2는 기존 최첨단 모델보다 컴퓨팅 효율성이 더 높다.
- 



Explain the advantages of this product.

The audi e-tron quattro concept is a plug-in hybrid electric sports car that has a range of 310 miles and can accelerate from 0 to 60 mph in just 4 seconds.



Tell me something about the history of this place.

The great wall of china was built in 221 bc by emperor qin shihuang to protect the emperor's capital from invaders from the north.



Write down the facts that you know about this flower.

It is a genus of flowering plants in the orchid family, orchidaceae. It is native to eastern asia and south east asia. It is a perennial flowering plant that grows up to a height of 1 m.





장점

- 전체 모델을 처음부터 학습할 필요 없음
- 학습 비용 대폭 감소
- 다양한 LLM 연결 가능
- GPT 스타일 대화 가능

한 줄 요약

BLIP-2는 Vision Encoder와 LLM 사이에 Q-Former를 추가하여, 이미지 정보를 LLM에 연결하는 효율적인 브리지(Bridge) 역할을 수행하는 VLM이다.





감사합니다