

LLaVA와 Qwen 모델

1. LLaVA

(Large Language and Vision Assistant)

LLaVA (Large Language and Vision Assistant)

1. LLaVA란?

LLaVA는 이미지를 이해하는 모델과 대규모 언어 모델(LLM)을 결합하여 사람과 자연스럽게 대화할 수 있도록 만든 VLM(Vision-Language Model)이다.

2023년에 발표되었으며 오픈소스 VLM의 대표 모델 중 하나이다.

기존 모델들이

이미지 분류

이미지 검색

이미지 설명 수준이었다면,

LLaVA는

이미지를 보고 질문에 답변

이미지 내용 설명

이미지 추론

이미지 기반 대화 까지 가능하도록 설계되었다.

논문: <https://arxiv.org/abs/2304.08485>

깃허브 : <https://github.com/Haotian-liu/LLaVA#fine-tuning-with-local-gpus>

Project Page : <https://llava-vl.github.io/>

Project Page : <https://llava-vl.github.io/>

LLaVA: Large Language and Vision Assistant

Visual Instruction Tuning

NeurIPS 2023 (Oral)

Haotian Liu*, Chunyuan Li*, Qingyang Wu, Yong Jae Lee

▶ University of Wisconsin-Madison ▶ Microsoft Research ▶ Columbia University

*Equal Contribution

📄 arXiv

📄 arXiv (LLaVA-1.5)

🔄 Code

🖥️ Demo

📄 Dataset

🔗 Model

🔥 **[NEW!]** LLaVA-1.5 achieves SoTA on 11 benchmarks, with just simple modifications to the original LLaVA, utilizes all public data, completes training in ~1 day on a single 8-A100 node, and surpasses methods that use billion-scale data.

LLaVA represents a novel end-to-end trained large multimodal model that combines a vision encoder and Vicuna for general-purpose visual and language understanding, achieving impressive chat capabilities mimicking spirits of the multimodal GPT-4 and setting a new state-of-the-art accuracy on Science QA.

Error

Could not load this space.

Please contact the author of the page to let them know.

2. LLaVA가 중요한 이유

LLaVA 이전에는 BLIP-2가 많이 사용되었다

BLIP-2 구조

```
graph TD; A[이미지] --> B[Vision Encoder]; B --> C[Q-Former]; C --> D[LLM]
```

이미지
↓
Vision Encoder
↓
Q-Former
↓
LLM

Q-Former라는 복잡한 모듈이 필요했다.

LLaVA는 훨씬 단순하게 설계되었다.

```
graph TD; A[이미지] --> B[CLIP ViT]; B --> C[Projection Layer]; C --> D[LLM]
```

이미지
↓
CLIP ViT
↓
Projection Layer
↓
LLM

복잡한 Q-Former를 제거하였다.

3. 전체 구조

이미지



CLIP Vision Encoder

(ViT-L/14)



Transformer Encoder

이미지를 패치로 분할 후
Transformer Encoder를 통해
이미지 특징을 추출

Image Features

0.21 -0.45 0.36 ... 0.77

ViT가 추출한 이미지 특징 벡터
(예: N개 토큰 × D차원)

Projection Layer

Image Features
(N × D_{vis})



MLP
(Linear Layer)



Projected Features
(N × D_{lm})

이미지 특징을 LLM이 이해할 수
있는 차원으로 변환
(선형 변환 + 비선형 활성화)

LLM 입력

System / User Prompt (텍스트 토큰)

<S> 다음 이미지를 설명해줘 .</S>

Projected image Features (이미지 토큰)

텍스트 토큰과 이미지 토큰을
함께 LLM의 입력으로 사용

LLM (예: Vicuna / LLaMA)



Transformer Decoder
(대규모 언어 모델)

입력된 텍스트 + 이미지 정보를
바탕으로 텍스트를 생성

자연어 답변 생성



작업자가 기계를 점검하고 있습니다.
안전모를 착용하고 있으며,
공장 내 설비를 확인하는 모습입니다.

LLM이 생성한 최종
자연어 답변 출력

4. 구성 요소

Vision Encoder

이미지를 이해하는 부분이다.

보통 CLIP의 ViT를 사용한다.

이미지
↓
Patch 분할
↓
Transformer
↓
이미지 특징 벡터

예시

작업자 사진



안전모
작업복
기계
공장

과 같은 특징을 벡터로 추출한다.

Projection Layer

LLaVA의 핵심 연결부이다.

CLIP이 생성한 이미지 특징은

768차원
1024차원
1408차원

등의 벡터이다.

하지만 LLM은

단어 임베딩 공간

에서 입력을 받는다.

따라서 중간 변환이 필요하다.

역할

CLIP Feature



Projection Layer



LLM Embedding

쉽게 말하면

이미지 언어 번역기

이다.



LLM

초기 LLaVA는

Vicuna

를 사용하였다.

이후에는

Llama

Qwen

Mistral

Phi

Gemma

등 다양한 LLM을 사용한다.






Figure 1: LLaVA network architecture.

논문 리뷰 : <https://cocoa-t.tistory.com/entry/%EB%85%BC%EB%AC%B8-%EB%A6%AC%EB%B7%B0-LLaVA-Large-Language-and-Vision-Assistant-Visual-Instruction-Tuning>

5. 실제 동작 과정

예시 이미지

공장에서 작업자가 기계를 점검

Step 1

Vision Encoder

이미지
↓
Feature Vector

생성

Step 2

Projection Layer

이미지 특징
↓
LLM 입력 형태 변환

Step 3

사용자 질문 입력

이 사람은 무엇을 하고 있는가?

Step 4

LLM 추론

이미지 특징
+
질문

함께 분석

Step 5

답변 생성

작업자가 산업용 설비를 점검하고 있습니다.

6. 왜 대화가 가능한가?

CLIP은

이미지 ↔ 텍스트

유사도만 계산한다.

BLIP은

이미지
↓
설명 생성

이 가능하다.

LLaVA는

이미지
+
질문
+
대화 이력

을 동시에 처리한다.

예시

사용자

사진 설명해줘

LLaVA

작업자가 기계를 점검하고 있습니다.

사용자

안전모를 쓰고 있나?

LLaVA

예, 안전모를 착용하고 있습니다.

사용자

위험 요소는?

LLaVA

보호장갑 착용 여부가 확인되지 않습니다.

이런 다중 턴 대화가 가능하다.

7. 학습 방식

LLaVA 논문의 가장 큰 특징은 GPT-4를 활용했다는 점이다.

단계 1

Projection Layer 학습

CLIP
↓
Projection
↓
LLM

연결

단계 2

Instruction Tuning

GPT-4가 생성한 데이터 사용

예시

이미지

↓

GPT-4 생성

질문:
사진에 무엇이 있는가?

답변:
작업자가 기계를 조작하고 있다.

수십만 개 생성

↓

LLaVA 학습

8. LLaVA가 잘하는 것

이미지 설명

Describe this image

시각 질의응답(VQA)

What is the person doing?

OCR 이해

표지판에 뭐라고 적혀 있는가?

차트 분석

그래프가 무엇을 의미하는가?

산업 이미지 분석

불량이 있는가?

Visual RAG

이미지



벡터 검색



LLM



답변

9. 한계

객체 탐지 전용 모델보다 정확도 낮음

YOLO 같은 모델은

위치
좌표
Bounding Box

를 정확히 찾는다.

LLaVA는 설명 중심이다.

환각(Hallucination)

없는 내용을 말할 수 있다.

예시

안전모가 보이지 않는데
"안전모를 착용하고 있습니다."

라고 답할 수 있다.

정밀 측정 불가

볼트가 몇 개인가?

길이가 몇 mm인가?

같은 정밀 작업은 약하다.

10. CLIP → BLIP → BLIP-2 → LLaVA 발전 과정

CLIP

= 이미지와 텍스트 연결



BLIP

= 이미지 설명 생성







BLIP-2

= 이미지와 LLM 연결



LLaVA

= 이미지 기반 대화





LLaVa 한 줄 요약 :

LLaVA는 CLIP 기반 **Vision Encoder**와 **LLM**을 **Projection Layer**로 연결하여 이미지를 이해하고 사람과 자연스럽게 대화할 수 있도록 만든 대표적인 오픈소스 Vision-Language Model이다.



2. Qwen

Qwen이란?

Qwen은 중국 Alibaba가 개발한 대규모 언어 모델(LLM) 계열이다.

원래는 텍스트 전용 LLM으로 시작했지만, 이후 이미지를 이해할 수 있는 Qwen-VL, Qwen2-VL, Qwen2.5-VL 등으로 발전하였다.

현재는 오픈소스 VLM 분야에서 LLaVA 계열과 함께 가장 많이 사용되는 모델 중 하나이다.

1. Qwen 발전 과정

Qwen (2023)



Qwen-VL(2023)



Qwen2 (2024)



Qwen2-VL (2024)



Qwen2.5-VL (2025)



Qwen3 (2025)



Qwen3-VL (2025)

https://www.alibabacloud.com/ko/solutions/generative-ai/qwen?_p_lc=1

Alibaba Cloud 모델 개요 제품 솔루션 가격 리소스 파트너 지원

Q OSS

KO 문의 문서 콘솔 로그인 무료 체험

솔루션 > Generative AI > Qwen

Qwen

전체 범위, 오픈 소스, 멀티모달, 다기능

영업팀에 문의하기

AI tokens 1M 받기

Alibaba Cloud가 "2025 가트너® 생성형 AI 혁신 가이드"에서 생성형 AI 모델 공급업체 부문 신흥 리더로 선정되었습니다.

Qwen 소개

Qwen Model 제품군

성공 사례

Qwen이 할 수 있는 일

Qwen-Agent


오픈소스 커뮤니티

Qwen의 친구들

Qwen 소개

Alibaba Cloud는 오픈소스 커뮤니티에 Qwen 모델, 일련의 거대언어모델(LLM)과 멀티모달 모델(MLLM)을 제공합니다. 최신 Qwen3 모델은 추론 성능, 속도 및 비용을 유연하게 제어할 수 있는 하이브리드 사고 모드('사고' 및 '비사고')를 채택하고 있습니다. 가법지만 강력한 Qwen3 모델은 코딩, 수학, 일반 능력 등에 대한 벤치마크 평가에서 다른 최상위 모델과 비교했을 때 경쟁력 있는 결과를 달성합니다. 119개 언어/방언과 MCP(Model Context Protocol)를 지원하는 Qwen3는 언어 장벽을 허물고 에이전트 기능을 강화하여 전 세계 오픈소스 및 독점 AI 모델의 새로운 벤치마크를 제시합니다.

다중 모달 모델인 Qwen-VL(대규모 언어-비전 모델), Qwen-TTS(텍스트-음성 변환 모델), Qwen-Audio는 교차 모달 처리를 지원하며, 최신 Qwen3-Omni는 텍스트, 오디오, 비전 모달리티를 동시에 처리하고 추론할 수 있습니다.



<https://qwen.ai/home>

Qwen

Qwen StudioQwen CodeResearchAPI PlatformAmbassador

ENDownloadTry Qwen Studio

Ask Qwen, Know More

لمعرفة المزيد: Ask Qwen

Image EditThinkingSearchWeb DevArtifactsDeep ResearchImage GenerationVideo Generation

Qwen Studio

Use Now

Qwen Studio is an AI assistant for everyone, powered by the Qwen series models. It's free to use, open to all, and ready to help with creativity, collaboration, and endless possibilities.



API Platform


Qwen API, which uses an API format compatible with the OpenAI API.



Download

Use Qwen on your phone or desktop.





Qwen

텍스트 전용 LLM

입력
↓
텍스트
↓
답변

GPT나 Llama와 유사

Qwen-VL

이미지 이해 기능 추가

이미지
+
텍스트
↓
답변

Qwen2-VL

멀티모달 성능 대폭 향상

- OCR
- 차트 분석
- 문서 이해
- 추론 능력

강화



Qwen2.5-VL

최신 계열



이미지
문서
차트
UI 화면
비디오

이해 능력이 향상됨



2. Qwen-VL 구조

LLaVA와 매우 유사하다.



3. Vision Encoder

이미지 특징을 추출한다.

주로 ViT 기반

이미지



Patch 분할



Transformer



Image Features

예시

공장 설비 사진



배관
밸브
모터
계기판

특징 추출

4. Vision Adapter

Qwen-VL의 핵심

역할

Vision Feature



Adapter



LLM Token

쉽게 말하면

이미지 언어 번역기

이다.

LLaVA의 Projection Layer와 비슷한 역할

LLaVA

Projection Layer

Qwen-VL

Vision Adapter



5. Qwen LLM

이미지 특징을 전달받아 추론한다.

예시

질문

사진을 설명해줘

답변

작업자가 산업용 설비를 점검하고 있습니다.

질문

위험 요소가 있는가?

답변

보호장갑 착용 여부가 확인되지 않습니다.



6. Qwen이 유명한 이유

OCR 성능

문서 읽기에 매우 강하다.

예시

송장
계약서
영수증
매뉴얼

입력

문서 이미지



출력

문서 내용 요약

7. 차트 이해

입력

막대 그래프



질문

가장 높은 값은?



답변

2025년 3분기입니다.

8. UI 이해

입력

웹 페이지 화면



질문

로그인 버튼은 어디에 있는가?



답변

오른쪽 상단에 있습니다.

9. 비디오 이해

Qwen2-VL 이후 강화된 기능

비디오



프레임 추출



시각 이해



설명 생성

예시

생산 라인 영상



작업자가 제품을 조립하고 있습니다.

10. 산업 현장에서 활용 설비 점검

설비 사진



이상 설명

품질 검사

제품 이미지



불량 설명

문서 자동화

작업 지침서



OCR



요약

Visual RAG

공장 이미지



매뉴얼 PDF



Qwen-VL



질문 응답

LLaVA와 비교


항목	LLaVA	Qwen2-VL
기반 LLM	Llama	Qwen
OCR	보통	매우 우수
문서 이해	보통	우수
차트 이해	보통	우수
비디오 이해	제한적	지원
산업 문서 활용	보통	우수

비전-언어 모델(VLM) 진화 과정

1. CLIP

= 이미지-텍스트 정렬

이미지와 텍스트를 같은
임베딩 공간에 정렬하여
유사도 계산



2. BLIP

= 이미지 설명 생성

이미지를 이해하고
자연어 설명(캡션)을 생성



3. BLIP-2

= 이미지와 LLM 연결


이미지 특징을 LLM이
이해할 수 있도록 변환하여
연결



4. LLaVA

= 이미지 기반 대화

간단한 연결(프로젝션 레이어)로
이미지와 LLM을 연결하여
대화 가능



5. Qwen2-VL

= 이미지 + 문서 + OCR +
차트 + 비디오 이해

더 넓은 멀티모달 입력을 이해하고
복잡한 문서/차트/비디오까지
처리 가능



Qwen3-VL은 이미지·문서·OCR·차트·비디오를 하나의 모델에서 처리하고, 긴 문맥 기반 추론과 Agent 연동까지 지원하는 최신 범용 멀티모달 AI 플랫폼이다.

Qwen3-VL: Sharper Vision, Deeper Thought, Broader Action

2025/09/23 · 69 minute · 13743 words · QwenTeam | Translations: 简体中文



QWEN CHAT ↗

GITHUB ↗

HUGGING FACE ↗

MODELSCOPE ↗

DISCORD ↗

<https://qwen.ai/blog?from=research.latest-advancements-list&id=99f0335c4ad9ff6153e517418d48535ab6d8afef>

Qwen3-VL은 알리바바가 2025년 9월에 공개한 오픈소스 최첨단 시각-언어 멀티모달 모델(VLM)입니다.

기존 멀티모달 AI들이 이미지를 단순히 '인식'하고 설명하는 수준이었다면, Qwen3-VL은 "보고, 깊게 생각하고, 직접 행동하는(See, Think, Act)" 고도의 인지 능력을 갖춘 것이 가장 큰 특징입니다.

💡 핵심 요약 3가지 포인트

- 🗨️ 멀티모달 추론 ('Thinking Mode' 도입)
 - 일반적인 답변을 내는 'Instruct' 버전 외에, 사람처럼 문제를 단계별로 숙고하는 'Thinking 버전'이 존재합니다. 복잡한 도표, 수학/과학(STEM) 문제 속 시각 자료를 보고 스스로 논리적인 추론 과정을 거쳐 정답을 도출합니다.
- 🖼️ 화면을 보고 조작하는 '비주얼 에이전트'
 - PC나 스마트폰의 화면(GUI)을 이미지로 실시간 인식하여 사람이 시키는 대로 앱을 조작하거나 웹사이트에서 작업을 수행하는 능력이 크게 강화되었습니다.
- 🏗️ 상용 모델급 스펙 (MoE 구조)
 - 대표 모델인 Qwen3-VL-235B 등은 필요한 부분만 활성화해 효율을 높이는 MoE(혼합 전문가) 구조를 채택했습니다. 덕분에 오픈소스 모델임에도 구글 Gemini Pro 같은 대기업의 상용 모델들과 대등하게 경쟁합니다.

주요 업그레이드 기능

기능	설명
초장문맥 지원 (256K~1M)	수백 페이지의 대형 문서나 몇 시간 분량의 긴 비디오를 끊김 없이 분석하고 정확한 타임스탬프를 찍어냅니다.
공간 및 3D 이해	이미지 속 사물의 위치 좌표를 정밀하게 짚어내는 2D Grounding을 넘어, 실제 세계의 깊이와 크기를 파악하는 3D Grounding까지 지원합니다.
강력해진 OCR	총 32개 다국어를 지원하며, 어둡거나 흐릿하고 기울어진 가혹한 환경의 글자까지 정확하게 읽어냅니다.



감사합니다