

제8장 Video AI 처리 Temporal Vision

시공간(Spatiotemporal) 정보 결합 및 모델 아키텍처의 진화

01

시공간 정보의 결합 원리

비디오 분석의 본질인 Spatial(공간)과 Temporal(시간) 차원의 통합 과정을 탐구합니다.

| Spatiotemporal Information

Spatial Context (공간)

프레임 내 객체의 형태, 질감, 색상 정보를 추출합니다. CNN과 ViT가 담당하는 2D 정적 특징 영역입니다.

- Object Detection
- Semantic Segmentation

Temporal Context (시간)

프레임 간의 변화, 움직임의 궤적, 사건의 순서를 파악합니다. 동적 맥락 이해의 핵심입니다.

- Action Recognition
- Trajectory Prediction

| Temporal Vision의 기술적 진화




| 광학 흐름 (Optical Flow)의 발전

연속된 프레임 사이의 픽셀 이동을 벡터로 표현하여 물체의 움직임을 추정하는 기법입니다.

🔧 **Classical:** Lucas-Kanade, Farneback (기하학 기반)

🧠 **Deep Learning:** FlowNet, PWC-Net (CNN 기반)

⚡ **SOTA:** RAFT (Recurrent 구조 기반 정밀 추정)



02

3D CNN Architectures

| 3D CNN 모델 비교 분석

Architecture	Core Concept	Key Advantage
C3D	고정 크기 3D 컨볼루션 필터 적용	단순하고 빠른 Spatiotemporal 학습
I3D	2D 사전학습 가중치를 3D로 확장(Inflation)	ImageNet 지식 전이를 통한 고성능 구현
SlowFast	Slow(공간) + Fast(시간) 이중 경로 채택	연산 효율과 분석 정밀도의 동시 확보

SlowFast Network


인간의 시각 시스템(P-cells & M-cells)을 모사한 혁신적 아키텍처입니다.

1. Slow Pathway

낮은 프레임 레이트로 고해상도 공간 정보를 처리하여 객체의 형태를 파악합니다.

2. Fast Pathway

높은 프레임 레이트로 저해상도 시간 정보를 처리하여 빠른 움직임을 포착합니다.



| Attention-based Efficiency

10x

Computational Efficiency

Paradigm Shift to Transformers

전통적인 3D CNN은 연산량이 시간축에 비례하여 급증하는 한계가 있었습니다. Video Transformer는 **Divided Attention** 기법을 통해 연산 효율을 획기적으로 개선하며 SOTA를 갱신하고 있습니다.

최신 Video Transformer 동향



TimeSformer

Space와 Time Attention을 분리
(Divided)하여 연산 효율 극대화



ViViT

시공간 튜브릿(Tubelet) 임베딩을
통한 고차원 특징 추출



Video Swin

3D Window-based Attention으
로 로컬 맥락 정보 강화

Space-Time Attention 메커니즘

Is Space-Time Attention All You Need for Video Understanding?




Figure 2. Visualization of the five space-time self-attention schemes studied in this work. Each video clip is viewed as a sequence of frame-level patches with a size of 16×16 pixels. For illustration, we denote in blue the query patch and show in non-blue colors its self-attention space-time neighborhood under each scheme. Patches without color are not used for the self-attention computation of the blue patch. Multiple colors within a scheme denote attentions separately applied along different dimensions (e.g., space and time for (T+S)) or over different neighborhoods (e.g., for (L+G)). Note that self-attention is computed for every single patch in the video clip, i.e., every patch serves as a query. We also note that although the attention pattern is shown for only two adjacent frames, it extends in the same fashion to all frames of the clip.

심도 있는 메커니즘 설명

- ✓ **Joint Attention:** 모든 시공간 패치를 동시에 고려 (높은 연산량)
- ✓ **Divided Attention:** 공간 축 연산 후 시간 축 연산 (TimeSformer 방식)
- ✓ **Factorized Attention:** 공간/시간 차원을 독립적인 인코더로 처리 (ViViT 방식)

※ 최근에는 장기 기억(Long-term)을 위한 메모리 토큰 활용 기법이 활발히 연구 중입니다.