

SECTION 8-4

시간 요약 기술 및 VLM

비디오 시공간 흐름의 압축과 Vision-Language Model 분석

PART 1

비디오 요약의 핵심 개념

대용량 시각 스트림을 최적화하여 보존하는 두 가지 패러다임

정적 요약 vs 동적 요약

정적 요약 (Keyframe-based)

비디오 전체에서 가장 대표성이 높고 정보량이 풍부한 **정지 영상(프레임)들의 서브셋**을 추출하는 분석 기법입니다.

- 컬러 히스토그램, 픽셀 차이 등의 메트릭 기반 중복 제거
- 의미 있는 이정표 정보 중심의 초고속 브라우징 실현
- 검색 인덱싱을 위한 경량 메타데이터 구축에 대단히 유리

동적 요약 (Video Skimming)

비디오의 핵심 서사 구조를 보존하면서도 중요도가 높은 **동영상 클립 조각들을 시퀀스로 병합**하는 썸네일 기술입니다.

- 연속적인 움직임과 타임라인 서사(Narrative) 흐름 유지
- 오디오 스트림과의 동기화를 동시 보존하여 정보 전달 극대화
- 보안 관제, 다큐멘터리, 스포츠 주요 장면 축약본 생산에 필수

PART 2

VLM 융합 메커니즘

시공간 프레임 임베딩을 언어 모델의 텍스트 토큰 시퀀스로의 맵핑

비디오 프레임 토큰화 아키텍처

📷 Spatial Feature Extraction:


비디오에서 다운샘플링된 각 프레임을 독립적으로 2D Vision Encoder(ViT 등)에 통과시켜 차원 높은 공간 특징을 얻습니다.

⚡ Spatiotemporal Projector (사영 레이어):

Q-Former, MLP Projection을 결합해 긴 시간 축 프레임 임베딩을 LLM이 한 번에 수용할 수 있는 고정 쿼리 토큰으로 병합 압축합니다.

🗣️ LLM Token Space Alignment:

압축된 시각 토큰은 사영 행렬을 통해 텍스트 임베딩 공간으로 정렬되어, LLM이 마치 한 줄의 글을 읽듯 비디오 서사를 이해할 수 있게 합니다.



PART 3

대표 오픈소스 VLM 분석

Video-LLaVA, Video-LLaMA, LLaVA-Next-Video 아키텍처 비교

주요 오픈소스 VLM 아키텍처 특성



Video-LLaVA

이미지와 비디오 임베딩을 공통의 통합 표현 공간으로 정렬하여, 추가 오버헤드 없이 강력한 제로샷 프롬프트 대응 능력을 구현한 초경량 모델입니다.



Video-LLaMA

비디오의 시각적 흐름뿐 아니라 음성오디오 신호(Audio Spectrogram)까지 동시에 결합 인코딩하는 오디오-비주얼 상호 보완형 추론 모델입니다.



LLaVA-Next-Video

고밀도 프레임 토큰 압축 기법을 고도화하여 가용 메모리 부하를 줄이고, 긴 러닝타임의 블랙박스/CCTV에 최적화된 최신 SOTA 모델입니다.