

Enterprise AI Tech Stack

Visual RAG & Vector DB 기술 스택 구축 전략

최신 VLM 트렌드와 목적별 벡터 데이터베이스 매칭 가이드

PART 01

Visual RAG 핵심 VLM 모델 라인업

1. 임베딩 & 리트리벌(Retrieval) 모델 트렌드

Next-Gen Champion

ColPali (PaliGemma 기반)

- **지연 상호작용(Late Interaction)** 기술의 문서 최적화 확장
- 텍스트 추출 단계 없이 문서 이미지를 패치 단위로 정밀 인코딩
- 표, 차트, 복잡한 인포그래픽이 포함된 PDF 검색에서 압도적 성능

Industry Standard

SigLIP / CLIP 시리즈

- 구글(SigLIP) 및 OpenAI(CLIP)의 검증된 멀티모달 솔루션
- 텍스트 쿼리와 이미지를 **동일 공통 차원 공간(Joint Space)**으로 정렬
- 일반 상품 이미지 검색이나 자연어 기반 이미지 탐색의 견고한 베이스라인

2. 멀티모달 생성(Generation) 모델 분석

Proprietary MLLM

상용 폐쇄형 고성능 모델

- **대상 모델:** GPT-4o, Claude 3.5 Sonnet, Gemini 1.5 Pro
- **특징:** 정밀하고 복잡한 시각적 정보 해석 및 추론 역량 극대화
- 방대한 컨텍스트 창을 지원하여 다중 문서 기반 고품질 답변 생성에 최적

Open-Source MLLM

효율형 오픈소스 모델

- **대상 모델:** Qwen2-VL, LLaVA-NeXT 시리즈
- **특징:** 인프라 비용 절감 및 기업 내부 **온프레미스 배포**의 필수 선택지
- 최신 벤치마크에서 상용 모델에 근접하는 뛰어난 시각 매체 이해력 증명

| 핵심 메커니즘: 지연 상호작용(Late Interaction)

-  **토큰 레벨 디테일 보존:** 이미지를 하나의 통합 벡터로 뭉뚱그리지 않고, 수많은 세부 패치 단위 벡터들의 집합으로 조밀하게 유지합니다.
-  **쿼리-패치 간 정밀 매칭:** 사용자의 텍스트 단어 토큰들이 이미지의 특정 구역(표의 행/열, 그래프의 범례 등)과 개별적으로 비교되어 높은 매칭 정밀도를 달성합니다.
-  **OCR 무결성 실현:** 텍스트 추출 엔진의 한계로 오인식되거나 누락되던 기호와 미세 텍스트 정보의 손실을 원천 차단합니다.

PART 02

Visual RAG에 최적화된 벡터 DB 솔루션

Visual RAG 지원 주요 벡터 DB 비교

벡터 DB	유형	Visual RAG 특화 강점	핵심 아키텍처 추천
Qdrant	오픈소스/클라우드	Rust 기반 고성능, 멀티 벡터 및 ColPali 원활한 네이티브 지원	토큰/패치 레벨 고정밀 문서 검색
Milvus	오픈소스/클라우드	엔터프라이즈급 대용량 분산 처리, 다양한 하이브리드 인덱싱	수억 건 이상의 초대규모 이미지 아카이브
Pinecone	완전 관리형 SaaS	운영 오버헤드 제로, 빠른 프로토타이핑, 비용 효율적 서버리스	인프라 관리 최소화 및 빠른 실서비스 배포
pgvector	PostgreSQL 확장	기존 RDB 인프라 자원 및 메타데이터 통합 관리 용이	중소규모 데이터셋 기반 복합 업무 시스템

목적별 최적의 기술 스택 조합 가이드

유형 A

기술 문서 및 복합 도서 중심 시스템


- **추천 조합:** ColPali + Qdrant / Milvus + Qwen2-VL
- **선정 배경:** 복잡한 문서 구조 분석을 위해 **멀티 벡터(Multi-Vector)** 연산 처리가 견고하게 지원되는 DB 인프라 체계가 필수적임

유형 B

쇼핑몰 상품 및 자연어 이미지 검색

- **추천 조합:** SigLIP/CLIP + Pinecone + GPT-4o
- **선정 배경:** 이미지당 1개의 고정된 단일 밀집(Dense) 벡터 공간만 다루므로, 운영이 편리한 SaaS 기반 벡터 저장소만으로 최고 효율 달성

| 아키텍처 도입에 따른 검색 정확도 체계



성공적인 이미지 검색 아키텍처 로드맵



1. 인프라 준비

VLM 구동을 위한 최적의
GPU 자원 및 대용량 벡터 DB
노드 설계



2. 임베딩 모델링

도메인 특성에 맞춰 ColPali
혹은 SigLIP 파이프라인 전개



3. 검색 최적화

멀티 벡터 인덱싱 구조 튜닝
및 하이브리드 필터링 적용



4. MLLM 연동

최종 생성 LLM 연동 및 지식
검증 시스템(Groundedness)
구축

엔터프라이즈 구축 시 극복 과제

- ⚠ **인프라 비용과 컴퓨팅 자원:** 멀티 벡터 모델(ColPali 등)은 이미지당 생성되는 벡터 수가 많아 스토리지 및 메모리 비용 가중. 정밀도 요구사항에 따른 압축/양자화 기법 고려 필요.
- ⚠ **입력 해상도 딜레마:** 도면이나 미세 부품 이미지의 경우 저해상도 임베딩 시 오인식 발생 위험. 타일링 분할 처리와 토큰 비용 사이의 명확한 트레이드오프 계산 필수.
- ⚠ **도메인 정렬(Modality Alignment):** 범용 VLM이 학습하지 못한 우리 회사 고유의 코드 체계나 제품 기호 인식은 전용 소규모 데이터셋을 활용한 추가 파인튜닝(Fine-tuning) 전략이 수반되어야 함.

THANK YOU

Visual RAG 아키텍처 설계를 마치겠습니다.

Contact: enterprise-solution@company.com