

단원 7-2. 데이터 큐레이션

프로젝트용 시각 데이터 구성 및 모델 성능 평가 실무

 산업용 데이터 분석 및 인공지능 실무  교육 시간: 4시간 (정제 및 성능 평가 부문)

01. 데이터 큐레이션의 본질

수집된 원천 데이터를 정제하고 가치 있는 정보로 필터링하는 AI 성공 핵심 엔진

왜 데이터 큐레이션이 필요한가?

▼ 가비지 인, 가비지 아웃(GIGO)의 방지

라벨링 오류, 흐릿한 이미지, 결측된 데이터를 그대로 모델에 주입하면 예측 신뢰도가 극도로 하락합니다. 철저한 필터링과 전처리를 통해 최적화된 고품질 데이터셋만 남깁니다.

⚖️ 극심한 데이터 불균형 극복


실제 생산 현장은 정상 데이터가 99.9%를 차지하는 불균형 상태입니다. 정교한 큐레이션과 데이터 증강 기법(Augmentation)을 통해 소수 불량 데이터를 균형 있게 복원합니다.

02. 시각 데이터 전처리 및 정제


현장의 열악한 이미지를 컴퓨터 비전 알고리즘이 학습하기 용이하게 변환하는 규칙

공정 비전 이미지 전처리 파이프라인


비전 모델 학습을 위한 핵심 3단계 전처리




영역 지정 (ROI Cropping): 원본서 불필요한 배경(공장 환경)을 제거하고, 핵심 검사 물체만 추출하여 연산 정확도를 극대화합니다.



명암·조도 정규화 (Normalization): 현장 설비 도어 개폐나 환경로 미세한 밝기 변화를 소프트웨어적으로 일정하게 상쇄시킵니다.



하이브리드 데이터 증강 (Augmentation): 수집된 소량의 불량 이미지를 회전, 대칭, 합성하여 수백 배 규모의 가상 데이터터넷으로 탄생시킵니다.



데이터 정제(Cleaning) 전후 비교 규칙

검사 단계	전처리 전 (Raw Data)	전처리 후 (Curated Data)	적용 기대 효과
이미지 크기	불규칙한 대용량 원본 파일 (해상도 저하 우려)	정형화된 640x640 ROI 영역 크롭 완료	학습 속도 3배 단축
조도 명암	현장 설비 외부 조도 간섭으로 인한 명암 노이즈 발생	히스토그램 평활화 기반 고대비 정규화 적용	검출 정확성 확보
클래스 분포	정상 99.8% : 불량 0.2% (극심한 극소 불균형 상태)	다각도 변환 및 인공 불량 데이터 증강 데이터셋 배합	오진율(Recall) 최적화

03. 라벨링 및 모델 평가 기준

인적 오류를 배제한 일관적인 어노테이션 규칙과 다각도 성능 분석 프로세스

신뢰도 검증을 위한 핵심 평가지표



정밀도 (Precision)

AI 모델이 불량으로 분류해 낸 항목 중 **실제 진짜 불량**이 매핑되는 비율입니다. 과탐(오경보)으로 인한 불필요한 제품 폐기 손실을 막기 위해 필수적인 수치입니다.



재현율 (Recall)

발생한 **실제 전체 불량품** 중 AI 검출기가 정확하게 찾아내 포착한 비율입니다. 불량이 소비자에게 그대로 유출되어 보상 리스크를 지게 되는 치명적 사고를 차단합니다.



mAP & F1-Score

Precision과 Recall의 균형 잡힌 조화를 평가하는 지표입니다. 데이터 편향성이 아주 심한 실제 상용 공정 현장의 최종 모델 판단 전투력의 척도가 됩니다.

데이터 큐레이션 파이프라인 4단계



1단계: 원천 필터링

흐릿함, 중복 촬영 및 촬영 규격을 벗어난 부적합 로우 데이터를 사전 일괄 배제합니다.



2단계: 전처리 및 정적화

설정된 공정 ROI(관심 영역)를 크롭하고 크기 리사이징 및 정적 조도 명암을 매핑합니다.



3단계: 표준 라벨링

규격화된 라벨링 기준서에 입각하여 경계 상자(Bounding Box)와 다각형 좌표를 기입합니다.



4단계: 교차 성능 검증

어노테이션 합의 수준을 교차 검토하고 고질적인 오진율 패턴을 모니터링하여 피드백합니다.

| 7-2 산업 데이터 전처리 및 정제 실습

-  **라벨링 툴(Annotation Tool) 실무 연동 및 결함 지정:** 제조 시각 데이터를 실무 툴과 연계해 미세 스크래치, 크랙 결함 등을 정교하게 태깅하는 어노테이션 규칙서 기준 실습을 전개합니다. (Reference: image_65c283.png)
-  **알고리즘 데이터 증강(Augmentation) 파이썬 실무 구현:** Python OpenCV 및 Albumentations 패키지를 통해 소량의 비대칭적 불량 샘플을 대칭, 전단 변형, 블러 노이즈 주입으로 변환하는 다차원 시뮬레이션을 구현합니다.
-  **Confusion Matrix 분석을 통한 모델 성능 세밀 교정:** 성능 평가 리포트의 거짓 양성(False Positive)과 거짓 음성(False Negative) 수치를 분석하여 취약 이미지 세트를 필터링하고 학습 셋을 2차 보완합니다.