

SERVICE ADVANCEMENT

모델 배포 최적화 및 산업 데이터 처리 파이프라인 고도화

01. 모델 배포 최적화

임베디드 엣지 및 클라우드 가속화를 위한 최적 배포 전략

| 모델 경량화 및 가속화 아키텍처

ONNX & TensorRT 양자화

FP32 파라미터를 정확도 유실 없이 INT8로 양자화하여 연산 효율을 증가시키고 온디바이스(On-Device) 엣지 장비의 가용 메모리 오버헤드를 대폭 절감했습니다.

동적 분산 추론 (Dynamic Batching)

실시간 영상 유입량에 맞추어 인공지능 추론 서버의 대기 시간을 유연하게 제어함으로써 단일 하드웨어 가속기 (GPU)당 하이브리드 스트림 소화량을 대폭 확장했습니다.

| 가속 추론 성능 개선 지표

72%

추론 지연 시간(Latency) 감축

가상 컨테이너 최적화 도입 성과

배포 환경을 경량화 도커 컨테이너 및 Triton 추론 엔진 아키텍처로 개편했습니다.

이를 통해 현장 엣지 디바이스 가동 효율을 극대화하고 동기식 패키징 대비 처리 속도를 3배 이상 단축하는 데 성공하였습니다.


02. 데이터 파이프라인 개선

밀리초(ms) 단위를 다루는 이벤트 기반 실시간 데이터 스트리밍

실시간 데이터 수집 아키텍처

 **분산 메시지 브로커:** Kafka를 이식하여 센서 및 비디오 대용량 프레임 패킷 유실을 완벽히 방지합니다.


 **Redis 실시간 캐싱:** 고주파 센서 데이터와 영상 타임스탬프를 기가헤르츠 메모리 내에서 매핑함으로써 동기식 지연을 최소화합니다.



데이터 파이프라인 개편 전후 비교

평가 항목	기존 단독형 파이프라인	분산 고도화 파이프라인	개선 효과
데이터 유입 제어	REST API 폴링 (자원 낭비 심각)	이벤트 주도형 메시지 큐 스트리밍	실시간 지연 감소
전처리 지연 속도	평균 320ms (CPU 기반 직렬 연산)	평균 18ms (GPU 커널 가속 및 병렬 처리)	처리 속도 94% 개선
장애 발생 감지	네트워크 유실 시 복구 불가	엣지 로컬 오프라인 로깅 캐싱 지원	데이터 무결성 99.9%

| 시스템 처리량 추이 (TPS)



파이프라인을 GPU 직접 메모리 액세스(DMA) 및 가속화 연산 프레임워크로 개편하여 센서/영상 패킷 처리 성능을 약 6배 대폭 향상했습니다.

| 고도화 로드맵 및 실행 단계



1단계: 아키텍처 수립

배포 대상 모델 가상화 빌드 및 엣지 장치용 최적 프로파일링 수립



2단계: 가속 엔진 이식

TensorRT 가속 이식 및 병렬 분산 큐잉 파이프라인 개발 완료



3단계: 액티브 러닝

엣지 디바이스 추론 성능 저하 시 데이터셋을 클라우드로 자동 피드백



4단계: 상용 통합 배포

엔터프라이즈 멀티-공정 관제 엣지 클러스터 가동 및 전사적 모니터링 적용