

# MAINTENANCE STRATEGY

지속 가능한 인공지능 서비스를 위한 아키텍처 및 모니터링 체계



---

# 01. 아키텍처 문서화

지식 자산화 및 안정적 운영의 기반



# | 문서화의 핵심 목적



## 운영의 일관성 확보

담당자 변경이나 비상 상황 시 즉각적인 대응이 가능하도록 표준화된 운영 지침과 시스템 구조를 명문화합니다.



## 확장성 및 효율성 극대화

시스템 컴포넌트 간의 의존성을 명확히 파악하여 향후 기능 확장 및 고도화 시 발생할 수 있는 리스크를 사전에 관리합니다.




# 통합 아키텍처 청사진

## 시스템 컴포넌트 상세 정의

- Edge-to-Cloud 데이터 파이프라인 흐름도
- AI 모델 추론 서빙 인프라 구성 (K8s/Docker)
- 데이터 보안 및 인증 프로토콜 규정
- 장애 복구(Disaster Recovery) 시나리오 포함

모든 아키텍처는 기술 변경 사항이 즉시 반영되는 "Living Document" 형태로 관리됩니다.





# | 문서화 관리 표준



## API 명세서

Swagger/OpenAPI 표준을 준수하여 각 모듈 간 인터페이스의 입출력을 상세 기록합니다.



## DB 스키마 & ERD

산업 데이터 저장 구조와 관계를 도식화하여 데이터 무결성 관리의 근거를 마련합니다.



## 인프라 설정 가이드

IaC(Terraform 등) 코드 설명과 서버 초기 세팅 절차를 문서화하여 자동화를 지원합니다.



## 02. 실시간 모니터링 계획

사후 대응을 넘어선 선제적 장애 관리



# | 통합 대시보드 구축

## Full-Stack 가시성 확보

Prometheus와 Grafana를 연동하여 하드웨어 자원부터 AI 모델의 추론 성능까지 단일 화면에서 관제합니다.

실시간 로그 수집(ELK Stack)을 통해 이상 징후 발생 시 즉각적인 원인 분석(Root Cause Analysis) 환경을 제공합니다.





# | 운영 목표 서비스 수준 (SLA)

99.9%

SERVICE UPTIME TARGET

## 고가용성 유지 전략

모니터링 알람 발생 후 5분 이내 인지, 15분 이내 대응을 목표로 하는 Incident 대응 프로세스를 수립했습니다.

이중화된 인프라와 자동 로드 밸런싱을 통해 중단 없는 서비스를 약속합니다.




# | 주요 관제 지표 및 임계치

| 관제 영역           | 핵심 지표 (KPI)         | 정상 범위    | 알람 임계치 (Warning) |
|-----------------|---------------------|----------|------------------|
| System Resource | CPU / GPU Usage     | 60% 이하   | 85% 초과 시         |
| API Performance | Average Latency     | 200ms 미만 | 500ms 초과 시       |
| AI Model Health | Data/Concept Drift  | -        | 성능 5% 하락 시       |
| Service Error   | HTTP 5xx Error Rate | 0.1% 미만  | 1% 초과 시          |



# | 선제적 알람을 통한 장애 예방 효과

장애 인지 및 대응 속도



구축 초기

안정화 단계 (AI 기반 예측 알람 적용)

지능형 알람 임계치 자동 최적화를 통해 실제 서비스 장애로 이어지기 전 선제적 조치가 가능한 비율이 약 75% 상승했습니다.



# 배포 후 유지보수 지원 모델



## 정기 예방 점검

매월 인프라 보안 패치 및 하드웨어 건전성 체크를 통해 노후화로 인한 장애를 사전 차단합니다.



## 전문 기술 지원 체계

이슈 발생 시 즉각 투입 가능한 전담 엔지니어 풀을 구성하여 24/7 밀착 지원 서비스를 제공합니다.