

한계 분석 및 배포 최적화

POC 시스템 성능 검증 및 산업용 모델 가속화 실습

01. PoC 시스템 한계 분석

현장 도입 전 기술적 병목 구간 식별

PoC 단계의 주요 병목 현상



추론 지연 (Latency)

실제 공정 라인의 속도를 따라가지 못하는 모델 응답 속도 문제
(Target: < 100ms)



자원 점유 (Memory)

FP32 기반 고용량 모델의 GPU 메모리 과점유로 인한 동시 처리 능력 한계




처리량 (Throughput)

다채널 영상 동시 처리 시 발생하는 서버 부하 및 프레임 드랍 현상


실제 환경과 PoC의 격차

현장 도입의 기술적 장벽

- 데이터 노이즈: 연구실 데이터와 다른 현장의 조도 및 진동 노이즈
- 환경 제약: Edge 디바이스의 제한된 연산 성능 및 전력 소모 제한
- 안정성: 24/7 가동 환경에서의 누적 메모리 리크 및 시스템 발열



부하 증가에 따른 성능 저하 추이



접속 세션 증가 시 지연 시간이 비선형적으로 급증하는 '임계점' 식별이 필수적입니다.

성능 목표 대비 현재 수치

450ms

현재 평균 추론 지연 시간


개선 목표치: 100ms 미만

현재 PoC 모델은 현장의 실시간 품질 검사 기준(10 FPS 이상)을 충족하지 못하고 있습니다. 약 4.5배의 가속화가 이루어져야 상용화가 가능합니다.

02. 모델 배포 최적화 실습


가속화 기술을 활용한 성능 극대화 전략

모델 가속화 3대 핵심 기술




양자화 (Quantization)

FP32 가중치를 INT8로 압축하여 정확도 손실을 최소화하며 연산량 감소



가지치기 (Pruning)

영향력이 낮은 뉴런의 연결을 제거하여 모델 경량화 및 추론 속도 향상



지식 증류 (Distillation)

무거운 교사 모델의 지식을 가벼운 학생 모델에 전수하며 고성능 유지



최적화 도구별 성능 비교


최적화 프레임워크	가속 배율 (fps)	정확도 유지	주요 특징
TensorRT (NVIDIA)	5.2x	99.1%	NVIDIA GPU 전용 하드웨어 가속 최적화
OpenVINO (Intel)	4.1x	98.5%	Intel CPU/VPU 최적화 및 경량화 도구
ONNX Runtime	3.4x	99.5%	다양한 하드웨어 간 범용적인 호환성 제공
TF-Lite (Edge)	2.8x	97.2%	모바일 및 저전력 임베디드 디바이스 특화

최적화된 배포 파이프라인

지속적 최적화 및 배포 (MLOps)

단순 배포를 넘어, 하드웨어별 최적화 엔진 빌드와 자동화된 성능 검증 과정을 통합 파이프라인으로 구축합니다.

이를 통해 모델 업데이트 시마다 최적의 가속 엔진을 생성하여 Edge 단말에 즉시 배포할 수 있는 환경을 조성합니다.



최적화 실습 로드맵

- ✓ ✓ 기본 모델 프로파일링: cProfile 및 TensorBoard를 활용한 병목 연산 구간(Op) 정밀 진단
- ✓ → 정밀도 보정 (FP16/INT8): PTQ(Post Training Quantization)를 통한 연산 정밀도 최적화 적용
- ✓ 🏗️ TensorRT 엔진 빌드: 네트워크 레이어 융합(Layer Fusion) 및 하드웨어 특화 커널 최적화
- ✓ ✎️ 검증 및 비교: 원본 FP32 모델과 최적화 모델 간의 mAP(정확도) 및 Latency 상관관계 분석